


Détection de la pêche artisanale malgache par imagerie satellitaire et apprentissage profond

Thomas Aubourg
Encadré par David Mouillot

¹ Université Claude Bernard Lyon 1, France

² MARBEC, France



Résumé À Madagascar, la dépendance économique à la pêche artisanale est un enjeu national majeur. Face à la vulnérabilité des écosystèmes, les institutions et les chercheurs soulignent la difficulté d'instaurer des mesures de sauvegarde efficaces, d'autant que seulement 11% des pirogues sont officiellement enregistrées. Ce constat motive la présente étude, qui démontre la capacité de l'imagerie satellite et de l'intelligence artificielle à quantifier cet effort de pêche jusqu'alors invisible.

Détecter ces embarcations sur des images à très haute résolution constitue un défi technique de taille. Pour entraîner les modèles, il faut recourir à l'imagerie Pléiades Neo (0,30 m/px), seule résolution permettant une

annotation humaine fiable. Cependant, pour des raisons de coût et de puissance de calcul, l'application à grande échelle doit se faire à une résolution inférieure (Pléiades, 0,50 m/px). Nous proposons donc une approche en deux étapes, combinant dégradation de l'image et détection.

Dans le cadre de ces travaux menés au laboratoire MARBEC, le modèle YOLO26 a été entraîné sur notre jeu de données Pléiades Neo. Pour optimiser la détection, une modification architecturale (tête P2 haute résolution) et un étirement spatial par interpolation bicubique ont été comparés. Pour le transfert de domaine, deux méthodes de génération synthétique ont été évaluées : une dégradation basée sur la physique des capteurs et une approche stochastique.

Les résultats montrent que la meilleure stratégie consiste à appliquer un étirement spatial sans modifier l'architecture, associé à une dégradation physique contrôlée. Cette preuve de concept permet désormais d'envisager la cartographie à grande échelle de l'effort de pêche artisanale malgache.

Mots-clés : Madagascar ; Pêche artisanale ; Apprentissage profond ; Télédétection ; YOLO26 ; Adaptation de domaine ; Très Haute Résolution.

Abstract In Madagascar, economic dependence on small-scale fisheries is a major national issue. Given the vulnerability of marine ecosystems, institutions and researchers emphasize the difficulty of implementing effective conservation measures, especially since only 11% of fishing canoes are officially registered. This situation motivates the present study, which demonstrates the potential of satellite imagery and artificial intelligence to quantify this previously invisible fishing effort. Detecting these vessels in very high-resolution imagery is a significant technical challenge. Training detection models requires the use of Pléiades Neo imagery (0.30 m/pixel), the only resolution that enables reliable human annotation. However, due to cost and computational constraints, large-scale deployment must be carried out at a lower resolution (Pléiades, 0.50 m/pixel). We therefore propose a two-stage approach that combines image degradation and object detection. As part of this work conducted at the MARBEC laboratory, the YOLO26 model was trained on our Pléiades Neo dataset. To optimize detection performance, an architectural modification (a high-resolution P2 detection head) and spatial upscaling through bicubic interpolation were compared. For domain adaptation, two synthetic image generation methods were evaluated : a sensor physics-based degradation approach and a stochastic approach. The results show that the most effective strategy is to apply spatial upscaling without modifying the model architecture, combined with controlled physics-based degradation. This proof of concept now paves the way for large-scale mapping of Madagascar's small-scale fishing effort.

Keywords: Madagascar · Small-scale Fisheries · Deep Learning · Remote Sensing · YOLO26 · Domain Adaptation · Very High Resolution Imagery

1 Contexte

Ce stage a été réalisé au sein de l'unité MARBEC (MARine Biodiversity, Exploitation and Conservation), sous la direction de David Mouillot, Professeur à l'Université de Montpellier. Il s'inscrit dans un projet de recherche pluridisciplinaire élargi cherchant à répondre à la question suivante « L'économie bleue peut-elle atténuer la pauvreté et l'exode rural en Afrique de l'Est ? ». Le projet s'articule autour de trois types d'économie bleue (la pêche artisanale, l'écotourisme et l'aquaculture) dans trois pays (Madagascar, Tanzanie et Mozambique) où les ressources agricoles sont menacées par le changement climatique et où les enjeux de développement durable sont parmi les plus critiques au niveau mondial. Ce stage s'attache ainsi à lever l'un des défis méthodologiques de ce projet : automatiser la quantification et la cartographie de la pêche artisanale sur les littoraux malgaches grâce à l'analyse d'images satellites par deep learning. Au-delà du cas d'étude, ce stage s'inscrit dans une stratégie scientifique qui vise à transférer, par dégradation, les connaissances d'un détecteur entraîné en très haute résolution vers des capteurs de résolution plus grossière.

2 Introduction

Sous l'effet croissant des pressions anthropiques, le déclin accéléré de la biodiversité marine s'impose comme l'un des défis environnementaux majeurs de notre siècle. À Madagascar, la mer n'est pas seulement un réservoir de biodiversité : c'est une source de survie. À l'échelle globale, les pêcheries artisanales représentent un pilier socio-économique et humain colossal : elles génèrent près de 44% de la valeur débarquée mondiale et font vivre au moins 492 millions de personnes [6]. Cette dépendance s'exprime avec une acuité maximale sur le continent africain, région où la pêche artisanale pèse le plus lourdement au sein du secteur halieutique en concentrant environ 67% des captures et en assurant 75% de l'apport nutritionnel régional [6]. Pourtant, bien que Madagascar figure explicitement parmi les pays clés de ces évaluations mondiales [6] et que la dépendance vitale vis-à-vis des ressources halieutiques y dépasse les 65% pour les populations côtières [31], ce sous-secteur demeure paradoxalement invisible dans les politiques de développement et les statistiques officielles. Cette dépendance alimentaire et économique repose sur des écosystèmes marins soumis à des pressions croissantes (surpêche industrielle, dégradation des littoraux, pression touristique) qui fragilisent un équilibre déjà précaire [11]. La Banque mondiale souligne à ce titre que la durabilité des ressources halieutiques côtières constitue désormais une urgence socio-économique autant qu'environnementale [33]. Assurer la durabilité de ces habitats côtiers est en effet la condition *sine qua non* pour pérenniser les revenus et la sécurité alimentaire de millions de Malgaches face à l'épuisement des stocks.

En réponse à cette menace, un réseau d'Aires Marines Protégées (AMP) s'est progressivement structuré le long des côtes malgaches. Cette dynamique s'appuie notamment sur un système de gestion communautaire pionnier, fédéré

par le réseau `mihari-network.org`, qui implique aujourd’hui près de 60 000 personnes sur 450 km de littoral. Toutefois, ces mesures de gestion demeurent souvent inopérantes sur le terrain : faute de moyens logistiques pour surveiller de telles étendues, leur impact réel sur la pression de pêche reste difficile à évaluer, rendant cette gouvernance locale pratiquement aveugle [29]. Ce déficit de données de terrain dépasse le seul cadre académique ; il constitue désormais une urgence politique et institutionnelle explicite, renforcée par l’adhésion de Madagascar à la Fisheries Transparency Initiative (FiTI).

Le dernier rapport FiTI de 2025 [12] illustre parfaitement cette opacité administrative : sur environ 48 000 pirogues estimées en activité, à peine 11% (soit 5 312 unités) sont officiellement enregistrées. Cette "invisibilité" statistique et administrative de la flotte artisanale n’est pas politiquement neutre : elle caractérise un déficit de ce que la littérature récente nomme l’équité de reconnaissance (*recognitionnal equity*). Comme le formalisent Blythe et al. (2026) [7] dans le cadre de l’Ocean Equity Index, les pêcheurs artisanaux sont structurellement non-reconnus et exclus des initiatives océaniques et des espaces de décision. Des études récentes ont cependant démontré qu’il est possible d’acquérir des données d’effort de pêche précises *in situ*. Randriatsara et al. (2025) [27] ont par exemple réussi à cartographier 397 sites de pêche sur 250 km² en équipant 570 pêcheurs de traceurs GPS. Néanmoins, si cette approche participative produit des résultats d’une grande fiabilité, elle impose un protocole logistique et financier extrêmement lourd, impossible à transposer à l’échelle d’un pays. Ce déficit de données terrain constitue aujourd’hui l’un des principaux obstacles à une gouvernance maritime, y compris des AMP, efficace et transparente.

Pour répondre à ce manque, la télédétection spatiale à Très Haute Résolution (THR) apparaît comme une approche prometteuse. Des synthèses récentes en observation de la Terre démontrent en effet la capacité croissante de l’imagerie satellite à cartographier la distribution des navires et à soutenir la gestion durable des environnements aquatiques [40,14]. Couplée aux méthodes d’apprentissage profond, cette approche permettrait d’estimer la pression spatiale exercée par les communautés de pêcheurs. Elle fournirait ainsi aux gestionnaires côtiers des indicateurs quantifiés et spatialisés, accompagnés d’un niveau de confiance explicite, condition nécessaire pour que ces sorties puissent effectivement éclairer des décisions opérationnelles.

Pour répondre à ces nouveaux défis d’observation, la convergence entre l’imagerie satellite et l’apprentissage profond a donné lieu à une production scientifique considérable. Toutefois, si les navires de grande taille dédiés à la pêche industrielle ou au transport sont relativement faciles à détecter grâce aux systèmes de suivi conventionnels et aux images satellites à basse résolution, les petites embarcations artisanales constituent un angle mort peu documenté, particulièrement en contexte tropical. Ces flottes se trouvent en effet structurellement exclues des dispositifs de surveillance classiques (*e.g.* AIS) et demeurent totalement absentes des corpus d’entraînement des algorithmes en IA [6]. Cette lacune revêt une dimension géographique marquée : une revue systématique récente de 133 études de détection de petites embarcations par satellite, publiées

entre 1992 et 2024, ne recense qu'un seul travail portant sur le continent africain, et aucun ne cible spécifiquement la pêche artisanale (Zucchetta et al., 2025)[40]. Celle-ci demeure ainsi l'une des activités maritimes les plus mal documentées par télédétection. C'est précisément cette lacune qui motive le présent travail : en s'attaquant à ces verrous algorithmiques, ce stage vise à quantifier une activité jusqu'ici difficilement observable. Il fournit ainsi le socle méthodologique indispensable à une évaluation à grande échelle de l'économie bleue malgache et à une gouvernance éclairée de ses ressources.

3 État de l'art

La détection d'objets par imagerie satellite repose aujourd'hui principalement sur des architectures combinant deux mécanismes. D'une part, la convolution, qui extrait hiérarchiquement les caractéristiques visuelles. D'autre part, l'attention, qui pondère dynamiquement l'importance des différentes régions [4]. Bien que popularisée par les modèles Transformers [30], l'attention s'intègre aujourd'hui efficacement aux réseaux convolutifs sous forme de modules légers, comme la *channel attention* [5].

Si l'attention globale des Transformers est redoutablement efficace, la lourdeur de ces modèles empêche leur déploiement à grande échelle sur de vastes tuiles satellitaires. À ce frein purement informatique s'ajoute une contrainte physique propre aux réseaux profonds : le Champ Récepteur Effectif (*Effective Receptive Field*, ERF), c'est-à-dire la zone d'information qui influence concrètement la décision du modèle. Comme l'ont établi Luo et al. (2017) [21], l'influence des activations se distribue de manière gaussienne autour du centre du champ théorique, de sorte que seule la zone centrale du champ récepteur contribue véritablement à la représentation d'un pixel. Ce phénomène est particulièrement critique pour de très petits objets, à l'instar des pirogues malgaches étudiées ici. Concrètement, si le champ récepteur d'une couche couvre 50 mètres de côté sur l'image réelle, une pirogue de 2 mètres de large y représente moins de 4% de la zone analysée; son signal se noie alors dans le bruit de fond. Bien que ces embarcations soient détectables sur des imageries à Très Haute Résolution (THR) comme Pléiades Neo (0,30 m/px), leur signature visuelle se dégrade rapidement à 0,50 m/px pour devenir imperceptible à résolution métrique. Pour traiter la richesse des scènes THR sans que cette information spatiale fine ne se dilue dans les couches profondes, il est crucial d'enrichir les convolutions avec des mécanismes d'attention locaux. C'est pourquoi la famille YOLO demeure le standard industriel et académique pour ce compromis précision/vitesse [3]. Ses dernières versions intègrent d'ailleurs explicitement ces modules d'attention au sein des blocs C3K2, tirant parti des deux approches sans exploser les coûts de calcul [16].

Dans le but d'améliorer la détection des petits objets, trois innovations architecturales ont été déterminantes : les réseaux pyramidaux (FPN) [19] pour

Le code source et l'ensemble des pipelines développés lors de ce stage sont accessibles sur GitHub : <https://github.com/Thomas-aub/pleiades-boat-detection>

analyser plusieurs échelles simultanément et ainsi répondre aux limites de l'ERF, les convolutions déformables [22] pour épouser la forme de l'objet, et les boîtes orientées (OBB) [10] pour isoler la cible du bruit de fond maritime. C'est l'intégration de ces mécanismes qui a permis l'émergence récente d'architectures ultra-spécialisées. Les travaux de Xu et al. (2025) [34] illustrent parfaitement cette tendance avec TCA-Net, un détecteur bi-étape (*two-stage*) atteignant l'état de l'art sur les petits navires. Pour y parvenir, leur modèle exploite des niveaux de détection à très haute résolution couplés à une fusion sémantique descendante et des modules d'attention. De plus, pour pallier l'instabilité de l'entraînement en très haute résolution (qui impose de petits lots d'images), ils substituent la classique normalisation de lot (*Batch Normalization*) par une normalisation par groupes (*Group Normalization*). Bien que redoutablement précises, ces architectures lourdes et spécifiques impliquent cependant un coût computationnel majeur.

Au-delà de l'architecture, plusieurs paradigmes permettent de pallier le manque de données annotées. L'apprentissage par transfert (*transfer learning*) réduit drastiquement le besoin en annotations spécifiques [37,25]. Plus récemment, les modèles de fondation (*foundation models*) [8], entraînés de manière auto-supervisée sur des données massives, acquièrent une compréhension visuelle globale facilement adaptable à de nouvelles tâches. Enfin, les méthodes d'adaptation de domaine (*domain adaptation*) sont cruciales en télédétection maritime pour contrer la forte variabilité des conditions d'acquisition (turbidité, luminosité, état de la mer) qui dégrade habituellement les performances [14].

Ces architectures ont démontré leur efficacité pour la détection des grands navires, que ce soit sur imagerie optique ou radar (SAR) [39]. La recherche active se structure aujourd'hui autour de deux axes complémentaires. Le premier est la robustesse géographique et environnementale des modèles : un détecteur performant en Méditerranée doit conserver ses performances dans des conditions radiométriques et climatiques radicalement différentes (eaux tropicales turbides, fortes luminosités, végétation côtière dense). Le second axe, cœur de ce travail, est la détection d'objets de très petite taille.

Comme le souligne la littérature récente, il n'existe pas de critère universel pour qualifier un "petit objet" [38]. Si les standards généraux comme MS COCO [20] retiennent le seuil de 32×32 pixels, les spécificités de la télédétection, notamment le découpage en tuiles (*tiling*) qui invalide les métriques de taille relative, imposent de s'en remettre au nombre absolu de pixels, une mesure qui reste toutefois sujette à interprétation face à l'hétérogénéité des résolutions satellitaires. Face à cette ambiguïté, on distinguera explicitement, dans le cadre de ce travail, deux réalités distinctes qu'il convient de ne pas confondre. La première désigne des objets de taille importante (habitation, véhicule) qui n'apparaissent « petits » qu'en raison de la faible résolution du capteur satellite, incapable de les restituer sur plus de quelques pixels. La seconde désigne un objet intrinsèquement petit, indétectable sur imagerie basse résolution et dont la détection requiert impérativement le recours à l'imagerie Très Haute Résolution (THR, résolution inférieure à 1 m/pixel). Ces deux catégories partagent

les mêmes solutions architecturales (têtes de détection multi-échelles via FPN, convolutions déformables), mais divergent sur plusieurs points fondamentaux. Premièrement, l’augmentation de la résolution spatiale s’accompagne mécaniquement d’une augmentation du bruit radiométrique et des détails non pertinents, dégradant le rapport signal/bruit et complexifiant la discrimination entre l’objet cible et le fond. Deuxièmement, cette même augmentation de résolution induit une forte variabilité intra-classe : un même objet peut présenter des apparences très différentes selon l’angle d’acquisition, les conditions d’éclairage ou l’état de la mer, ce qui complique l’apprentissage de représentations robustes. Troisièmement, la taille des images THR génère une charge computationnelle et un coût de stockage significativement supérieurs à ceux des imageries conventionnelles, nécessitant des stratégies de tuilage ou de traitement par fenêtres glissantes [9]. Quatrièmement, l’imagerie THR constituant elle-même la donnée la plus précise disponible, il devient impossible de recourir à un capteur de résolution supérieure comme vérité terrain : les annotations reposent alors sur une interprétation humaine d’images bruitées, ce qui introduit des biais potentiels et limite la fiabilité des métriques d’évaluation. Les pirogues malgaches appartiennent sans ambiguïté à cette seconde catégorie.

Pour les petites embarcations en général, plusieurs approches complémentaires ont été proposées dans la littérature pour améliorer la détection au-delà des seules innovations architecturales : l’exploitation du sillage comme signature hydrodynamique caractéristique [35], le croisement entre imagerie optique et radar SAR [13], et l’utilisation du signal AIS ou VMS comme supervision ou comme vérité terrain de localisation [39]. Ces méthodes, conçues pour les navires motorisés ou équipés, sont inapplicables aux pirogues malgaches. L’absence de motorisation supprime toute signature de sillage. La construction en bois sombre confère une réflectance optique et radar extrêmement faible, incompatible avec les seuils de détection des méthodes basées sur la réflectance des matériaux. L’absence de tout système AIS ou VMS à bord exclut enfin tout recours aux méthodes de fusion signal-image. À titre d’illustration, l’étude la plus récente consacrée au suivi de petites embarcations par télédétection (Menéndez-Blázquez et al., 2025 [24]) repose précisément sur ces leviers indisponibles ici : une imagerie Planet-Scope à 3 m/px, une digitalisation manuelle des bateaux et une validation croisée avec l’AIS, dans un contexte méditerranéen de pêche de plaisance. Or, aucun de ces ressorts n’est mobilisable pour les pirogues malgaches, ce qui impose une chaîne entièrement automatisée sur imagerie THR.

Enfin, bien que la détection maritime THR soit un domaine actif, les travaux existants s’inscrivent quasi-exclusivement dans le régime des grands navires motorisés en eaux tempérées. Les jeux de données publics de référence (tels que DOTA [36] ou xView [17]) ne contiennent aucune instance de pirogue traditionnelle en bois, et très peu d’environnements côtiers tropicaux. Ce biais de représentation [14] rend impossible l’application directe de modèles pré-entraînés sans adaptation, imposant la création d’un corpus annoté spécifique à Madagascar.

En résumé, la détection des pirogues malgaches constitue un cas limite pour les approches actuelles. Cumulant une taille critique (quelques pixels), une réflec-

tance minimale (bois sombre), l’absence de signature dynamique (pas de sillage) et de données auxiliaires (pas d’AIS), ces embarcations rendent inopérants les leviers de détection classiques. Ce travail sort donc du cadre standard de la télédétection maritime : ni les architectures génériques, ni les corpus existants ne peuvent être mobilisés tels quels, ce qui motive l’ensemble des choix méthodologiques présentés par la suite.

4 Constitution d’un corpus de données terrain

Avant même d’envisager l’entraînement d’une architecture d’apprentissage profond, le premier défi méthodologique a résidé dans la création d’une vérité terrain. Aucun jeu de données public ne capturant la spécificité des littoraux malgaches, la construction d’un corpus de bout en bout s’est imposée comme un prérequis incontournable. Cette section détaille la chaîne de traitement mise en place pour transformer des acquisitions satellitaires brutes en données exploitables.

Notre corpus s’appuie sur deux sources d’imagerie satellitaire distinctes, caractérisées par des résolutions et des modalités d’accès différentes : Pléiades Neo et Pléiades. Les images Pléiades Neo ont fait l’objet d’une programmation spécifique (*tasking*) financée par l’unité MARBEC, permettant de couvrir l’ensemble du littoral malgache sur une fenêtre temporelle définie. Elles offrent la plus haute résolution spatiale native actuellement disponible sur le marché commercial, soit 0,30 m/px (la résolution de 0,15 m/px proposée par ailleurs étant issue d’un algorithme de post-traitement). Les images Pléiades, dont la résolution est légèrement inférieure (0,50 m/px), ont quant à elles été mises à disposition gratuitement pour la recherche publique via le dispositif DINAMIS (Dispositif Institutionnel National d’Accès Mutualisé en Imagerie Satellitaire) de l’IR Data Terra.

La couverture Pléiades Neo englobant la totalité de la côte malgache, un échantillonnage stratégique a été nécessaire pour cibler les scènes à annoter. Afin de garantir la représentativité du modèle, nous avons cherché à maximiser la diversité écologique en sélectionnant des images couvrant un large panel d’habitats côtiers (récifs coralliens, marais salants, mangroves, herbiers marins et milieux d’eaux froides) [26]. De même, pour assurer une forte densité d’embarcations, notre sélection s’est concentrée sur les zones portuaires et les littoraux ruraux fortement tournés vers la pêche artisanale [28]. Ma sélection des images Pléiades a suivi cette même logique d’échantillonnage, tout en appliquant un filtrage strict pour exclure les scènes présentant une couverture nuageuse trop importante.

Une fois les données acquises, la phase d’annotation a été réalisée via le logiciel SIG QGIS. Cette opération consistait à délimiter manuellement chaque embarcation par une boîte orientée (OBB) et à lui attribuer une classe. Les pirogues, objets centraux de cette étude, s’avérant impossibles à identifier de manière fiable à l’œil nu sur l’imagerie Pléiades (0,50 m/px), l’annotation de vérité terrain n’a pu être menée que sur les images Pléiades Neo (0,30 m/px).

Cette limite perceptuelle justifie d’ailleurs directement la démarche de génération de domaine synthétique présentée ultérieurement (cf. Section 5.3). L’annotation manuelle demeure un processus particulièrement chronophage et intrinsèquement soumis au biais d’interprétation humaine. Pour en atténuer l’impact et accélérer la production, j’ai mis en place une boucle d’apprentissage actif (*active learning*). Dans un premier temps, les prédictions d’une version intermédiaire de notre modèle ont été confrontées aux saisies manuelles, ce qui a permis d’identifier et de corriger certaines annotations manquantes. Dans un second temps, ce modèle pré-entraîné a été utilisé pour générer des pré-annotations sur de nouvelles scènes. Bien qu’une validation visuelle exhaustive de l’image soit restée indispensable pour corriger les erreurs de la machine, cette approche hybride a permis un gain de temps considérable pour finaliser le jeu de données.

L’extraction des statistiques spatiales issues de cette campagne manuelle d’annotation permet de quantifier objectivement le défi algorithmique posé par nos cibles (Table 1).

Class ID	Class	Effectif	Longueur (px)	Longueur (m)	Largeur (px)	Largeur (m)	Aire (px ²)	Allongement
0	Pirogue	894	23.42	7.03	6.93	2.08	177.58	3.58
1	Double hulled pirogue	756	36.47	10.94	20.27	6.08	820.82	1.87
2	Small Motorboat	365	37.95	11.39	13.72	4.11	561.15	2.84
3	Medium Motorboat	116	115.81	34.74	28.26	8.48	3960.01	4.13
4	Ferry	1	46.42	13.93	11.56	3.47	536.51	4.02
5	Sailboat	107	62.82	18.85	18.73	5.62	1190.95	3.57
6	Large Motorboat	22	285.31	85.59	72.43	21.73	31853.76	4.11
8	Pirogue (Hard)	74	16.10	4.83	5.72	1.72	104.74	2.97
9	UNKNOWN	199	31.10	9.33	13.44	4.03	1168.05	2.38
10	Rowboat	6	43.90	13.17	15.24	4.57	676.00	2.99
11	Fishing trap	107	175.33	52.60	105.04	31.51	22217.27	1.77

TABLE 1 – **Statistiques morphologiques détaillées des embarcations par classe avant étirement.** Les dimensions et propriétés géométriques (longueur, largeur, aire, allongement) sont des moyennes calculées sur l’effectif de chaque classe.

Comme le montre ce tableau, les pirogues traditionnelles (classes 0 et 1) occupent une surface extrêmement restreinte sur l’image. Avec une longueur moyenne d’à peine 23.4 pixels et une largeur de 6.9 pixels sur l’imagerie Pléiades Neo (0,30 m/px), leur aire moyenne stagne autour de 177.6 px². Outre leur petitesse, ces statistiques mettent en évidence la géométrie très effilée de ces embarcations, avec un ratio longueur/largeur dépassant le facteur 3. On retrouve ainsi les caractéristiques présentées dans l’état de l’art, qui justifient formellement la qualification de « petits objets » ainsi que le choix d’une détection par boîtes orientées.

Afin de transformer ces données brutes en un format directement ingérable par les réseaux de neurones, l’intégralité des opérations a été orchestrée au sein d’un pipeline de prétraitement automatisé. Ce flux de travail débute par une normalisation radiométrique globale de l’image : un étirement des percentiles (1% - 99%) est appliqué pour standardiser le contraste, suivi d’une correction gamma fixée à 0,8 afin d’éclaircir les zones d’ombre maritimes. Les annotations

vectérielles initiales sont simultanément converties vers le format attendu par le modèle (YOLO), avec un filtrage écartant systématiquement les objets dont la fraction visible est inférieure à 10%. Le corpus de 13 images satellites est ensuite scindé en ensembles d’entraînement (70%), de validation (15%) et de test (15%). Cette division s’opère strictement à l’échelle de l’image source via un algorithme d’assignation glouton (*greedy assignment*) pondéré par la rareté des classes, ce qui permet d’équilibrer la distribution tout en excluant formellement toute fuite de données spatiales (*spatial leakage*).

L’étape la plus structurante de ce pipeline demeure toutefois le tuilage spatial (*tiling*). Le poids considérable des images Pléiades Neo, oscillant entre 3 et 6 Go par fichier, rend toute lecture directe en mémoire GPU techniquement irréalisable. Le script découpe ainsi ces vastes emprises en tuiles de 1536×1536 pixels, sans chevauchement, en projetant les coordonnées de chaque boîte englobante dans le repère local de la tuile. Enfin, pour éviter que le processus d’apprentissage ne soit noyé sous une surreprésentation d’étendues maritimes vides, le pipeline intègre un module de réduction de l’arrière-plan. Ce dernier filtre les tuiles vierges d’annotations pour plafonner leur proportion à un maximum strict de 15% au sein du jeu d’entraînement final.

5 Méthodologie

5.1 Détection de petits objets

Disposer d’une vérité terrain sur des images très hautes résolutions n’est que la première étape vers l’automatisation de la surveillance maritime. Encore faut-il que le réseau de neurones soit capable de percevoir ces annotations de quelques pixels. Face à des objets dont l’aire stagne autour de 178 px^2 , les approches de détection conventionnelles atteignent rapidement leurs limites physiques et computationnelles. L’objectif de cette section est donc de présenter la stratégie algorithmique déployée pour extraire efficacement l’information spatiale de ces embarcations. Pour relever ce défi, notre démarche s’est structurée en trois temps : nous détaillerons successivement la sélection d’un modèle de base géométriquement adapté à nos cibles (YOLO26), son altération architecturale via l’ajout d’une tête de détection à très haute résolution (Tête P2), et enfin la stratégie d’agrandissement artificiel des images visant à soulager la charge d’apprentissage du réseau.

Choix du modèle

La première étape méthodologique a consisté à sélectionner une architecture capable d’isoler nos cibles tout en répondant aux limites imposées par le Champ Récepteur Effectif (ERF), telles qu’établies dans l’état de l’art.

L’utilisation du modèle de fondation SAM 3 (*Segment Anything Model*), via une approche par segmentation, a constitué notre première hypothèse de travail. Toutefois, l’abandon de cette piste n’est pas lié à un manque de performance. Au contraire, le modèle montre des capacités respectables en *zero-shot* (dont

les métriques comparatives sont reportées dans le Tableau 2). Le véritable point bloquant a été sa taille excessive : avec près d’un milliard de paramètres, l’architecture de SAM 3 demande une infrastructure matérielle bien trop lourde pour le cadre de ce stage. Il nous était techniquement impossible de le réentraîner (*fine-tuning*), ou même de l’utiliser pour de l’inférence à grande échelle. Au-delà de ces limites matérielles, le choix d’un tel réseau soulève un problème éthique et environnemental. Son coût énergétique est disproportionné, ce qui interroge directement sur la sobriété numérique de notre démarche. En fin de compte, il ne nous a pas semblé justifié de mobiliser une architecture aussi gourmande pour notre problématique.

Une deuxième piste a consisté à évaluer RF-DETR, un modèle de fondation basé sur l’architecture DINO (les scores initiaux en *zero-shot* étant également présentés dans le Tableau 2). Toutefois, cette approche s’est heurtée à une limitation technique majeure : aucune version pré-entraînée de ce modèle ne prend actuellement en charge la prédiction par boîtes englobantes orientées (OBB, *Oriented Bounding Boxes*). Or, la morphologie très allongée des pirogues, leur orientation souvent diagonale et leur forte densité spatiale (les embarcations étant régulièrement regroupées) rendent cette fonctionnalité incontournable pour éviter le chevauchement des prédictions et l’inclusion excessive de bruit de fond.

Une troisième alternative nous a conduits à étudier TCA-Net [34], une architecture récente spécifiquement conçue pour les petits navires orientés. Bien que prometteuse sur le papier, cette approche a été écartée pour deux raisons majeures. D’abord, l’absence d’implémentation publique et de poids pré-entraînés disponibles en ligne rendait son adoption impossible dans notre contexte de faible volume de données. Ensuite, sa structure bi-étape (*two-stage*), alourdie par des modules d’attention et de raffinement successifs, induit une forte lenteur d’inférence d’après ses auteurs. Ce coût computationnel élevé constitue un frein rédhibitoire pour traiter rapidement les volumes massifs requis par la cartographie du littoral malgache.

Face à ces contraintes matérielles, géométriques et logicielles, notre choix final s’est porté sur une quatrième architecture : le modèle YOLO26m-OBB d’Ultralytics [16]. Pré-entraîné sur le jeu de données de référence DOTAv1, ce détecteur mono-étape (*one-stage*) gère nativement l’orientation des cibles tout en garantissant la rapidité nécessaire au déploiement à grande échelle. De plus, l’efficacité de cette famille de modèles a déjà été validée dans la littérature pour la détection de petits navires en milieu maritime (Laval et al. [18]).

Tête P2

Sur le plan structurel, la famille YOLO exploite un réseau pyramidal de caractéristiques (FPN) permettant de générer des prédictions à différentes échelles spatiales qui sont ensuite fusionnées. Dans sa configuration standard, l’architecture YOLO26 s’articule autour de trois têtes de détection. La tête opérant à la plus haute résolution, conventionnellement nommée P3, exploite les cartes de caractéristiques issues du troisième bloc convolutif du réseau extracteur (*backbone*). Toutefois, pour des cibles de la taille des pirogues malgaches, nous avons

postulé que le passage par trois blocs d'agrégation induisait déjà une dilution spatiale critique. Pour pallier ce risque, une évolution architecturale a été expérimentée lors de ce travail : l'intégration d'une tête de détection supplémentaire, dite P2, greffée en amont, dès la sortie du deuxième bloc convolutif (cf. Figure 1). L'objectif est mécanique : intercepter et analyser le signal visuel à un stade précoce afin de minimiser drastiquement l'impact de l'ERF. L'entraînement de cette architecture modifiée s'est appuyé sur l'apprentissage par transfert (transfer learning) : la quasi-totalité de l'architecture initiale a hérité des poids pré-entraînés (1058 sur 1074 paramètres initiaux), tandis que la nouvelle branche P2 a fait l'objet d'une initialisation aléatoire.

Étirement

Alors que l'intégration de la branche P2 visait à adapter l'architecture interne pour capturer les signaux les plus faibles, une approche alternative consistait à agir directement sur les données en entrée en agrandissant artificiellement les images. La littérature récente s'appuie fréquemment sur des techniques de Super-Résolution (SR) par apprentissage profond pour reconstruire les détails spatiaux manquants. Toutefois, cette voie présentait deux obstacles méthodologiques majeurs. D'une part, l'entraînement de ces modèles requiert des couples d'images à résolutions multiples parfaitement alignées spatialement, ou, à défaut, une modélisation extrêmement robuste des processus de dégradation optique. D'autre part, la SR ajoute une lourde charge computationnelle et une couche d'incertitude générative à la chaîne de traitement. Étant donné que notre protocole prévoyait déjà d'évaluer la robustesse du détecteur sur des images Pléiades (0,50 m/px) à l'aide de données Pléiades Neo (0,30 m/px) artificiellement dégradées, l'ajout d'une étape de reconstruction synthétique aurait superposé trop de biais potentiels. Cette complexité excessive aurait compromis notre capacité à isoler la cause des erreurs et à attester de la fiabilité réelle des performances de détection. En conséquence, nous avons privilégié une approche de redimensionnement purement analytique. Le recours à l'interpolation bicubique constitue ici un choix délibérément prudent : bien qu'elle n'améliore en rien la résolution effective de l'image, elle garantit une transformation spatiale déterministe, exempte de tout biais génératif. Dans le cadre d'un protocole d'évaluation rigoureux, cette intégrité vis-à-vis du signal d'origine s'avère plus précieuse qu'un gain de résolution potentiellement illusoire. La détermination du facteur d'agrandissement optimal a fait l'objet d'une exploration empirique systématique via une recherche par grille (*grid search*).

Étude d'ablation

Afin d'évaluer la pertinence de ces choix architecturaux, nous avons mené une étude d'ablation rigoureuse. En amont, pour pallier le déficit de données sur certaines embarcations, les classes sous-représentées ont été sémantiquement fusionnées (par exemple, le regroupement des différentes tailles de bateaux à moteur). L'ensemble des images a ensuite été soumis à notre pipeline de prétraite-




FIGURE 1 – **Modification de l’architecture YOLO26 pour l’intégration de la tête haute résolution P2.** Le diagramme détaille l’extraction des caractéristiques depuis le *backbone* jusqu’aux têtes de détection (*head*). Les modules d’agrégation (Upsample, Concat, C3K2) et la nouvelle tête de prédiction ajoutés pour former la branche P2 sont mis en évidence en rouge.

ment détaillé précédemment. Pour garantir une comparabilité de nos métriques, un protocole strict a été appliqué à nos cinq entraînements : la répartition (80% pour l’entraînement, 20% pour la validation) ainsi que les images spécifiques assignées à chaque ensemble sont restées rigoureusement identiques à travers toutes les configurations. De même, les hyperparamètres d’entraînement du modèle ont été maintenus strictement constants pour chaque expérience (l’ensemble des valeurs utilisées est détaillé en annexe A). Cette démarche contrôlée a ainsi permis d’isoler et de comparer objectivement l’impact de nos deux variables clés, à savoir l’intégration de la tête P2 et l’application d’un agrandissement spatial (étirement avec un facteur 2), dont les résultats sont détaillés dans le Tableau 2.

5.2 Généralisation du modèle

Les phases initiales d’optimisation du modèle ont révélé un plateau de performance précoce, dont les scores détaillés sont présentés dans la section (cf. Section 6). Afin de déterminer si ce verrou provient d’un déficit quantitatif de données ou d’une incapacité du réseau à généraliser face à l’hétérogénéité des littoraux malgaches, un double protocole expérimental a été mis en place. Cette attention portée au degré de corrélation entre ensembles d’entraînement et de validation répond à une faiblesse récurrente du domaine : parmi les 133 études recensées par Zucchetta et al. (2025) [40], seule une minorité valide ses modèles sur des scènes réellement indépendantes, la majorité s’en remettant à un découpage aléatoire qui tend à surestimer les performances en conditions de déploiement.

Évaluation de la sensibilité au volume de données

Dans un premier temps, l’objectif était d’évaluer strictement l’impact du volume de données d’entraînement sur les performances, indépendamment des problématiques de généralisation inter-domaine. À cette fin, les images ont été découpées en tuiles sans chevauchement, et l’ensemble du jeu de données a été partitionné en 10 sous-ensembles de taille égale, en veillant à maintenir une distribution de classes homogène. Les tuiles provenant des mêmes images sources, ce partitionnement permet une évaluation intra-domaine (*in-domain*) minimisant le décalage de distribution (*domain shift*). Afin de garantir la fiabilité statistique des mesures tout en maintenant un coût de calcul réaliste, l’expérience d’évaluation a été répétée à trois reprises de manière indépendante. Pour chacune de ces trois itérations, 2 sous-ensembles (représentant 20 % du volume total) ont été tirés aléatoirement pour constituer l’ensemble de validation strict (non vu durant l’optimisation). Les 8 groupes restants (80 %) ont ensuite servi à tracer une courbe d’apprentissage (*learning curve*) via un entraînement cumulatif. Concrètement, pour chaque itération, le modèle a d’abord été entraîné sur un unique sous-ensemble, puis un second y a été ajouté, et ainsi de suite jusqu’à l’intégration des huit disponibles. Pour s’affranchir d’un éventuel biais lié à la séquence d’introduction des données, l’ordre d’ajout de ces 8 groupes a été randomisé lors de chaque répétition de l’expérience. Cette approche, combinant un sous-échantillonnage aléatoire répété (pour la validation) et une randomisation

séquentielle (pour l'entraînement), permet de moyenner les performances sur trois configurations distinctes et de générer des intervalles de confiance pertinents à chaque palier de volume de données, confirmant ainsi la robustesse de la tendance observée.

Évaluation de la capacité de généralisation

Dans un second temps, la capacité de généralisation du modèle a été évaluée en comparant deux stratégies de partitionnement des données, induisant des degrés de corrélation spatiale opposés entre les ensembles d'entraînement et de validation.

La première configuration correspond au partitionnement aléatoire classique par tuiles (*intra-image*), couramment employé par défaut dans la littérature. Cette approche induit une très forte corrélation spatiale et radiométrique : des tuiles adjacentes issues d'une même image source se retrouvent simultanément dans l'entraînement et l'évaluation. Elle permet ainsi d'observer les capacités maximales de détection de notre modèle dans un contexte idéal, c'est-à-dire lorsqu'il n'a pas besoin de s'adapter à un nouvel environnement géographique.

La seconde configuration, à l'inverse, applique une séparation stricte au niveau de l'image source (*inter-image*). Les scènes assignées à la validation sont géographiquement distinctes de celles de l'entraînement, garantissant une absence totale de fuite spatiale (*spatial leakage*). Cette configuration constitue notre cas de référence réaliste : elle évalue la véritable robustesse du modèle et sa capacité à généraliser ses prédictions face à des littoraux malgaches inédits. La comparaison de ces deux configurations permet ainsi de quantifier la baisse de performance liée au seul décalage de distribution spatiale (*domain shift*).

5.3 Génération de domaine synthétique

Comme souligné lors de la constitution de la base de données (cf. Section 4), l'annotation manuelle des pirogues n'est véritablement réalisable que sur l'imagerie Pléiades Neo (0,30 m/px). Cependant, en raison de leur poids, de leur coût d'acquisition et de leurs conditions d'accès, un suivi spatio-temporel à large échelle reposant exclusivement sur ces images s'avère inenvisageable. Les images Pléiades (0,50 m/px), plus légères et accessibles pour la recherche publique via le dispositif DINAMIS, constituent donc l'alternative opérationnelle de référence. Il demeure toutefois un obstacle méthodologique majeur : l'impossibilité de générer directement une vérité terrain sur ces images pour y entraîner et évaluer notre modèle. Le dernier axe de ce travail s'est par conséquent attaché à combler ce fossé de résolution en transposant les acquis du domaine Pléiades Neo vers le domaine Pléiades.

L'évaluation de cette génération de domaine se heurte à la contrainte fondamentale qui a motivé ce travail : l'absence de vérité terrain sur l'imagerie Pléiades. Ne pouvant mesurer la performance de détection réelle sur ce domaine cible, notre méthodologie est par nature strictement distributionnelle. Les indi-

capteurs employés ici doivent donc être considérés comme des proxys de la réussite du transfert, et non comme des garanties de performance algorithmique.

Dans cette optique, notre évaluation s’articule autour de deux axes : une analyse quantitative des distributions et une étude qualitative de la sémantique. Dans un premier temps, nous mesurons mathématiquement la validité des images synthétiques via deux métriques standards. D’une part, la *Kernel Inception Distance* (KID) quantifie l’écart global entre la distribution des images artificielles et celle des véritables images Pléiades. D’autre part, la similarité cosinus, calculée dans l’espace des *embeddings* SatDINO, permet de s’assurer que le contenu sémantique de l’image source n’a pas été détruit lors de la transformation.

Dans un second temps, il est crucial de comprendre comment ces images sont visuellement « perçues » par un réseau de neurones profond. Nous avons donc extrait les vecteurs caractéristiques (*features*) des trois ensembles (Pléiades Neo, Pléiades réelles et images générées) via l’espace latent du modèle fondationnel SatDINO. Pour rendre cette information multidimensionnelle interprétable pour l’œil humain, nous avons appliqué l’algorithme de réduction de dimensionnalité UMAP. Cette projection en 2D permet d’observer si les images générées parviennent effectivement à combler le fossé de domaine en se regroupant (*cluster*) avec les véritables images Pléiades.

Dégradation guidée par la physique

Une première approche consiste à se baser sur la physique des capteurs spatiaux pour émuler au mieux l’imagerie cible. S’appuyant sur les spécifications officielles d’Airbus et du CNES concernant Pléiades [1] et Pléiades Neo [2], cette méthode modélise précisément la chaîne d’acquisition via la bibliothèque Python open-source satharmony [15].

L’algorithme applique quatre transformations successives. D’abord, un ré-échantillonnage spatial (*spatial downsampling*) ramène la résolution de 0,30 m à 0,50 m/px. Il est couplé à une Fonction d’Étalement du Point (PSF) calibrée sur la Fonction de Transfert de Modulation (FTM) réelle mesurée en vol pour simuler le flou optique intrinsèque des lentilles de Pléiades.

Ensuite, un ajustement spectral est opéré. Les bandes spectrales du capteur Pléiades étant physiquement plus larges que celles de Neo, une correction harmonise la sensibilité des canaux Rouge, Vert et Bleu, tout en injectant un léger bruit résiduel simulant les incertitudes d’étalonnage.

La troisième étape simule le bruit de Poisson. Ce phénomène naturel, dépendant du signal ($\sigma^2 \propto I$), induit une variance de bruit asymétrique (plus forte sur les zones lumineuses). L’algorithme reproduit cette propriété pour dégrader le rapport signal-sur-bruit (SNR) global de l’image autour de 43,5 dB, conformément au bruit thermique et photonique réel du capteur Pléiades.

Enfin, pour s’affranchir des limites de mémoire informatique, ce processus est appliqué par tuiles (carrés de 2048 pixels) avec une zone de chevauchement symétrique, garantissant la continuité visuelle et évitant les artefacts de bord.

Approche stochastique par dégradation aléatoire

Les résultats de cette première approche (anticipés dans la section 6.3) révéleront les limites d’une simulation strictement physique : l’espace latent généré peine à couvrir l’entièreté de la distribution des véritables images Pléiades. Face à ce constat, nous avons posé l’hypothèse d’un changement de paradigme : l’objectif d’un jeu de données d’entraînement ne serait pas d’atteindre un réalisme nominal absolu, mais de maximiser la couverture des variations possibles.

Pour tester cette hypothèse de diversité, nous nous sommes inspirés des travaux de Wang et al. (2021) [32] sur Real-ESRGAN. La stratégie consiste à modéliser la dégradation du signal non plus comme une séquence physique rigide, mais comme un processus stochastique. L’application aléatoire d’opérations (flou, redimensionnement, bruit) agit alors comme un mécanisme massif d’augmentation de données (*Domain Randomization*). Notre implémentation adapte toutefois ce pipeline aux contraintes satellitaires : l’écart de résolution étant resserré, la seconde passe de dégradation (trop destructrice) a été supprimée, et les plages de tirage aléatoire ont été recalibrées pour rester physiquement cohérentes.

Concrètement, l’ordre d’application des modules et le choix des altérations (filtre gaussien, Sinc 2D, bruit de Poisson ou additif) sont mélangés aléatoirement pour chaque image. Les paramètres sous-jacents (étendue du flou, force du bruit) sont quant à eux tirés au sein de plages continues. En exposant le modèle à cet espace de dégradation élargi et parfois extrême, notre hypothèse est que le réseau sera contraint d’extraire les caractéristiques sémantiques invariantes des pirogues, l’empêchant de sur-apprendre une signature de bruit spécifique. Cette variabilité totale a donc pour ambition de générer un espace de configurations suffisamment vaste pour englober le domaine cible, bien que sa validité effective doive être confirmée empiriquement.

6 Résultats

6.1 Détection de petits objets sur corpus Pléiades Neo

Le Tableau 2 présente les performances de détection obtenues sur le corpus Pléiades Neo selon cinq configurations distinctes du modèle YOLO26. À titre de référence, le tableau intègre également les évaluations initiales en *zero-shot* des modèles de fondation SAM 3 et RF-DETR, écartés lors de la sélection architecturale. On observe notamment que SAM 3 démontre des capacités de généralisation remarquables pour un modèle non affiné (mAP50 de 45,2%), tandis que RF-DETR échoue totalement à extraire le signal de ces cibles (mAP50 de 2,2%).

Concernant notre architecture cible, le modèle YOLO26 appliqué en configuration *zero-shot* (sans réentraînement) affiche des métriques initiales basses, avec notamment un F1-Score de 15,9% et un mAP50 de 16,4%. L’affinage (*finetuning*) de cette architecture de base sur notre jeu de données entraîne une progression majeure de l’ensemble des indicateurs, hissant la précision à 70,4% et le mAP50 à 65,1%.

L’intégration de la tête de détection haute résolution (Tête P2) au modèle affiné se traduit par une baisse des performances, avec un mAP50 régressant à

59,4% et un F1-Score chutant à 59,5%. À l'inverse, la configuration combinant le modèle affiné et l'étirement spatial des images (facteur 2) s'impose comme la plus performante de l'étude. Cette méthode maximise l'intégralité des indicateurs de référence, atteignant une précision de 74,9%, un rappel de 65,7%, un F1-Score de 70,3% et un mAP50 atteignant 71,8%. Enfin, la combinaison simultanée de la Tête P2 et de l'étirement génère des résultats intermédiaires (mAP50 de 60,7%), supérieurs à l'utilisation de la Tête P2 seule, mais nettement en deçà de la configuration n'utilisant que l'étirement.

Configuration	Précision (%)	Rappel (%)	F1-Score (%)	mAP50 (%)
YOLO26 (<i>zero-shot</i>)	22.2	12.5	16.0	16.4
YOLO26 (<i>finetuned</i>)	70.4	58.9	64.1	65.1
YOLO26 + Tête P2 (<i>finetuned</i>)	63.8	55.3	59.2	59.4
YOLO26 + Étirement (<i>finetuned</i>)	74.9	65.7	70.0	71.8
YOLO26 + Tête P2 + Étirement (<i>finetuned</i>)	67.8	60.7	64.1	60.7
RF-DETR (<i>zero-shot</i>)	4.2	0.1	0.2	2.2
Sam3 (<i>zero-shot</i>)	45.6	54.1	49.5	32.1

TABLE 2 – Analyse de l'impact des optimisations architecturales et spatiales sur les performances de détection (Pléiades Neo).

6.2 Généralisation du modèle sur corpus Pléiades Neo

La Figure 2 illustre l'évolution des performances de détection en fonction du volume de données d'entraînement. L'observation des courbes révèle que la performance globale du modèle (mAP50 et F1-Score) croît de manière continue sur l'ensemble de la plage étudiée, sans atteindre de plateau de saturation strict à 100 % des données. Le gain de performance le plus marqué est observé lors du passage de 12,5 % à 25 % du volume total. Au-delà du palier de 75 % des données, la progression des métriques tend à ralentir pour adopter une croissance plus modérée. Par ailleurs, la représentation graphique de la variance (zones ombrées) montre une réduction de l'intervalle de confiance à mesure que le volume de données augmente. Enfin, on constate une progression simultanée et synchrone des courbes de précision et de rappel tout au long de l'ajout de données.

Le Tableau 3 quantifie l'impact de la corrélation spatiale lors de l'évaluation du modèle en comparant deux méthodes de partitionnement. La configuration présentant la plus forte corrélation (partitionnement par tuiles en *intra-image*) affiche les performances les plus hautes de l'étude, avec un mAP50 s'établissant à 78,9 % et un F1-Score à 75,4 %. À l'inverse, lorsque l'évaluation est réalisée selon un partitionnement strictement géographique (*inter-image*), simulant un déploiement réaliste sans fuite spatiale, l'ensemble des métriques enregistre une baisse. Le mAP50 chute de 7,1 points pour s'établir à 71,8 %, tandis que le F1-Score recule à 70,3 %. Parmi les différentes métriques, c'est le rappel qui subit la baisse la plus significative entre les deux configurations, passant de 73,2 % à 65,7 %.




FIGURE 2 – **Courbes d'apprentissage cumulatives : impact du volume de données d'entraînement (Pléiades Neo).** Cette figure illustre l'évolution des principales métriques de performance (mAP50, F1-Score, Précision et Rappel) en fonction de la proportion du jeu d'entraînement utilisée. Les zones ombrées représentent la variance des résultats sur les différentes itérations de l'expérience. À des fins d'interprétation matérielle, ces pourcentages se traduisent par les équivalences quantitatives suivantes : 12,5 % (1 sous-ensemble) représente environ 248 objets annotés, 50,0 % (4 sous-ensembles) correspond à environ 992 objets, et 100,0 % (8 sous-ensembles) regroupe la totalité des données d'entraînement disponibles, soit environ 1 984 objets annotés.

Configuration	Précision (%)	Rappel (%)	F1-Score (%)	mAP50 (%)
Déploiement réaliste (<i>inter-image</i>)	74.9	65.7	70.0	71.8
Partitionnement par tuiles (<i>intra-image</i>)	77.5	73.2	75.3	78.9

TABLE 3 – **Évaluation de la robustesse par variation de la corrélation spatiale (Pléiades Neo).**

6.3 Génération de domaine synthétique

Les résultats de l'évaluation des approches de génération de domaine synthétique sont quantifiés par les Figures 3 et 4 et visualisés spatialement par la Figure 5.

La matrice de la Figure 3 détaille les scores de la métrique KID mesurés entre les différents ensembles d'images. L'écart initial entre l'imagerie d'origine (Pléiades Neo) et le domaine cible (Real Pléiades) s'établit à environ 3,05. L'approche par dégradation physique (*Physic Simulated*) permet de réduire marginalement cet écart, atteignant une valeur d'environ 2,99 par rapport aux véritables images Pléiades. À l'inverse, la simulation stochastique (*Stochastic Simulated*) génère la distance KID la plus élevée face au domaine cible (environ 3,70), marquant un éloignement statistique de la distribution globale. À titre de référence, les distances intra-domaines (observables sur la diagonale de la matrice) se situent quant à elles dans une fourchette comprise entre 2,15 et 2,49.

La matrice de la Figure 4 présente les scores de similarité cosinus médians évalués entre ces mêmes paires de domaines, où une valeur plus élevée traduit une plus forte similarité. L'imagerie d'origine (Pléiades Neo) affiche un score de 0,329 avec le domaine cible (Real Pléiades). L'approche par dégradation physique (*Physic Simulated*) enregistre une similarité très proche, bien que légèrement inférieure, s'établissant à 0,313 face aux véritables images Pléiades. Enfin, de manière cohérente avec les observations de la métrique KID, la simulation stochastique (*Stochastic Simulated*) affiche le score de similarité le plus bas face au domaine cible (0,275). À titre de comparaison, les scores de similarité intra-domaines (évalués sur la diagonale) varient entre 0,287 et 0,366.

La Figure 5 illustre la projection UMAP en deux dimensions des vecteurs caractéristiques extraits par SatDINO pour ces mêmes domaines. L'observation des enveloppes convexes montre que les points correspondant à l'imagerie source (*Real Neo*, en rouge), à la simulation physique (*Simulated Physic PHR*, en vert) et à la simulation stochastique (*Simulated Stochastic PHR*, en orange) se superposent fortement et se concentrent au sein d'une même sous-région restreinte de l'espace latent. Il est particulièrement notable qu'aucun de ces trois ensembles ne parvient à recouvrir l'entièreté de la distribution spatiale des points correspondant à l'imagerie cible (*Real PHR*, en bleu). De plus, on remarquera visuellement l'importante intersection globale de ces quatre domaines.

7 Discussion

Détection

L'évaluation de nos modèles met en évidence une grande différence d'efficacité entre les stratégies testées. D'une part, l'agrandissement spatial des images (étirement) s'impose comme une stratégie purement géométrique très efficace, offrant un gain de performance de près de 5 points sur le mAP50 et le F1-Score. D'autre part, l'intégration de la tête de détection haute résolution (P2), bien




FIGURE 3 – **Évaluation de la similarité inter-domaines par la mesure de la distance KID.** La matrice présente la valeur médiane de la Kernel Inception Distance (KID) calculée pour chaque paire de domaines d'imagerie évaluée. Une métrique plus faible indique une plus grande proximité statistique entre les distributions visuelles comparées (une diminution de la valeur correspond à une similarité accrue).




FIGURE 4 – **Évaluation de la similarité inter-domaines par la mesure de la similarité cosinus.** La matrice présente la valeur médiane de la similarité cosinus calculée pour chaque paire de domaines d'imagerie évaluée. Une métrique plus élevée indique une plus grande proximité sémantique entre les représentations extraites (une augmentation de la valeur correspond à une similarité accrue).




FIGURE 5 – Projections UMAP des vecteurs caractéristiques SatDINO

que théoriquement pertinente pour contrer la dilution spatiale propre aux petits objets, dégrade significativement les capacités du réseau.

Ce contre-résultat empirique peut s'expliquer par trois vulnérabilités principales liées à cette modification architecturale.

Premièrement, opérer une détection sur des cartes de caractéristiques aussi précoces expose le modèle à une surabondance de détails locaux non pertinents. Au lieu d'isoler la signature sémantique de la pirogue, la tête P2 capte un bruit de fond complexe et très présent dans l'imagerie Très Haute Résolution (*e.g.* reflets, écume, houle), ce qui génère une confusion lors de la prédiction.

Deuxièmement, cette approche introduit une difficulté majeure d'optimisation au sein du processus d'apprentissage par transfert. L'ajout d'une nouvelle branche de détection, dont les poids sont initialisés aléatoirement, crée un déséquilibre vis-à-vis du reste de l'architecture qui dispose déjà de poids pré-entraînés robustes. Ce décalage génère des gradients instables qui perturbent l'affinage du modèle. Dans notre contexte où le volume de données annotées demeure restreint, le réseau ne disposerait donc pas d'assez d'exemples pour forcer la convergence de cette tête aléatoire sans basculer prématurément dans le surapprentissage (*overfitting*).

Troisièmement, le mécanisme de normalisation du modèle aggrave directement cette instabilité. Comme le soulignent les récents travaux de Xu et al. (2025) [34], l'exploitation de cartes de caractéristiques à très haute résolution impose de fortes contraintes de mémoire GPU, obligeant à réduire drastiquement la taille des lots d'images (*batch size*) durant l'entraînement. Or, l'architecture YOLO repose nativement sur une Normalisation de Lot (*Batch Normalization*).




FIGURE 6 – **Évaluation visuelle des approches de détection sur l'imagerie Pléiades Neo et Pléiades.** Illustration des performances des configurations testées. Les boîtes **vertes** marquent les détections correctes, les **rouges** les oublis, et les **bleues** les fausses détections.

lization), dont les statistiques s’effondrent sur de petits lots. Contrairement à Xu et al. [34] qui ont substitué cette couche par une Normalisation par Groupes (*Group Normalization*) pour stabiliser l’apprentissage de leur tête haute résolution, notre greffe d’une tête P2 a conservé l’architecture de normalisation originelle de YOLO pour préserver l’apprentissage par transfert. Cette dernière faiblesse architecturale ouvre cependant une piste d’amélioration claire pour de futurs développements.

Au-delà de ces considérations architecturales, il convient d’évaluer ces métriques absolues dans le contexte très spécifique de notre tâche. Atteindre un F1-score de 70,0% et un score mAP50 de 71,8 % sur des cibles aussi minuscules que des pirogues artisanales constitue un résultat très encourageant. Cela prouve qu’un réseau de neurones profond est bel et bien capable d’extraire la signature visuelle, pourtant extrêmement faible, de ces embarcations en bois non motorisées.

Toutefois, il est impératif de souligner que ces scores ont été obtenus sur notre corpus Pléiades Neo (0,30 m/px). Ils représentent un contexte d’observation idéal et doivent donc être considérés comme un plafond de performance théorique. Le déploiement opérationnel sur des images Pléiades standards (0,50 m/px) entraînera inévitablement une perte d’information spatiale.

Enfin, il convient de mettre en perspective ces résultats à l’aune d’une limite inhérente au cadre de cette étude : l’ensemble des scores présentés dans les Tableaux 2 et 3 est issu d’entraînements uniques (*single runs*). Faute de ressources computationnelles et de temps pour mener une validation croisée rigoureuse (telle qu’un *K-fold*), il n’est pas encore possible d’affirmer avec une absolue certitude statistique que l’écart de performance observé, qu’il s’agisse du gain induit par l’étirement ou de la chute liée à la tête P2, s’affranchit totalement de la variance naturelle d’initialisation du modèle (le bruit *run-to-run*). Néanmoins, l’amplitude de ces variations dessine des tendances expérimentales très intéressantes, qui viennent appuyer de manière empirique nos hypothèses théoriques. Si la littérature récente en écologie marine place légitimement la barre très haut en matière d’évaluation (à l’instar des validations 10-fold de Marsaglia et al., [23] ou des recommandations de Zucchetta et al. [40] sur l’indépendance des jeux de test), ces premiers scores constituent une base de travail solide et prometteuse. La confirmation définitive de ces dynamiques architecturales nécessitera simplement d’itérer ces entraînements dans de futurs travaux afin d’en extraire des intervalles de confiance fiables.

Généralisation

L’évaluation croisée de nos expériences met en évidence que le plafonnement des performances de notre modèle est de nature multifactorielle : il découle à la fois d’un déficit quantitatif de données et d’une sensibilité marquée au décalage de distribution spatiale (*domain shift*).

D’une part, l’analyse des courbes d’apprentissage révèle qu’une augmentation du volume d’entraînement permet non seulement d’améliorer les métriques de détection, mais aussi de stabiliser le réseau en réduisant drastiquement la va-

riance de ses prédictions. Le modèle n'ayant pas atteint de plateau de saturation strict, il est manifeste qu'une marge de progression directe est encore exploitable en fournissant simplement plus d'exemples au réseau.

D'autre part, la comparaison des stratégies de partitionnement (*intra-image* contre *inter-image*) confirme que le détecteur peine encore à transposer ses acquis face à des paysages côtiers inédits. La baisse de performance lors d'une évaluation simulant un déploiement réaliste (sans fuite spatiale) souligne la difficulté du modèle à extraire la signature des pirogues lorsque le contexte environnemental (récifs, couleur de l'eau, type de côte) diffère radicalement de celui observé à l'entraînement.

Ces deux constats, bien que distincts, appellent une solution commune. Pour espérer franchir un nouveau palier de performance et rendre le modèle pleinement opérationnel, il sera indispensable d'enrichir le jeu de données d'entraînement. Cet enrichissement devra être non seulement quantitatif (augmenter le volume absolu d'annotations), mais surtout qualitatif, en maximisant la représentativité et la diversité géographique des littoraux malgaches afin de forcer le réseau à s'affranchir du contexte local.

Dégradation

L'évaluation de nos méthodes de dégradation met avant tout en évidence un point fondamental : les images d'origine (Pléiades Neo) et les images cibles (Pléiades) sont intrinsèquement très proches. Les métriques quantitatives (KID) l'illustrent clairement. La distance initiale entre ces deux domaines s'établit à un score KID de 3,05, associé à une similarité cosinus de 0,329. À titre de comparaison, ces valeurs s'éloignent assez peu des variations mesurées au sein d'un même domaine, puisqu'une comparaison d'images Neo entre elles donne un score KID de 2,18 et une similarité cosinus de 0,338. Cette forte proximité statistique se traduit qualitativement sur les projections UMAP, où les deux nuages de points se superposent de façon presque continue. Il est donc essentiel d'interpréter nos résultats en gardant à l'esprit que notre marge de manœuvre initiale pour rapprocher ces domaines était extrêmement étroite.

Dans ce contexte, nos deux approches de dégradation (physique et stochastique) révèlent des comportements asymétriques. Sur le plan quantitatif et rigoureux du KID, la logique est respectée : l'approche guidée par la physique génère des images dont la distribution statistique est très proche de celle des véritables images Pléiades (KID minimal), tandis que la méthode stochastique s'en éloigne mathématiquement.

Cependant, l'analyse visuelle des espaces latents via UMAP apporte une nuance importante. Bien que les enveloppes convexes de ces projections (validées par notre contrôle de graines en Annexe B) montrent une superposition quasi identique des ensembles Neo, physiques et stochastiques, cette observation doit être interprétée avec prudence, l'UMAP ne préservant ni les densités ni les distances globales. Elle permet néanmoins d'illustrer qu'aucun artefact sémantique majeur n'a été introduit. En revanche, le verdict quantitatif du KID confirme que la simulation stochastique, malgré son application aléatoire de flous

et de bruits, ne parvient pas à formaliser une distribution capable d’englober plus fidèlement la variabilité des véritables images cibles.

Ce constat interroge la pertinence d’une telle approche stochastique au sein de notre pipeline. Si l’application de dégradations aléatoires complexes ne démontre pas de supériorité distributionnelle face à un modèle physique bien calibré, elle perd son avantage théorique principal. Face à des domaines satellitaires déjà si proches, cette lourde machinerie algorithmique pourrait finalement être avantageusement remplacée par une simple étape d’augmentation de données classique lors de l’entraînement de la détection.

8 Conclusion

Ce stage partait d’un constat simple mais critique pour Madagascar : la pêche artisanale, bien que vitale pour des millions de personnes, reste un angle mort de l’observation maritime. Pour sortir ces milliers de pirogues traditionnelles de leur invisibilité, il fallait d’abord lever un verrou technologique : réussir à les détecter automatiquement depuis l’espace pour, à terme, évaluer la pression de pêche.

Nos expérimentations ont prouvé que ce pari était tenable. En associant l’imagerie Très Haute Résolution (Pléiades Neo à 0,30 m/px) à une architecture adaptée (YOLO-OBB), nous avons réussi à capter la signature visuelle extrêmement faible de ces petites embarcations en bois. Plutôt que de complexifier l’architecture du réseau, c’est finalement l’étirement spatial des images, une approche plus pragmatique, qui nous a permis d’atteindre des performances très encourageantes, avec un mAP50 de 71,8 %. Par ailleurs, notre étude sur la dégradation des images a posé un jalon rassurant : pour transférer ce modèle vers l’imagerie Pléiades standard (0,50 m/px), une simulation basée sur la physique des capteurs s’avère la méthode la plus pertinente et la plus stable.

Ces résultats constituent une excellente rampe de lancement pour mes trois prochaines années de thèse. Techniquement, la feuille de route à court terme est claire : nous devons diversifier géographiquement nos données d’entraînement pour apprendre au réseau à s’affranchir des différents paysages côtiers (*domain shift*), et valider sa robustesse statistique via une validation croisée (*K-fold*). Sur le plan architectural, la réintroduction d’une branche haute résolution (P2) exigera également d’adapter les mécanismes de normalisation du modèle aux contraintes de petits lots, en substituant notamment la classique *Batch Normalization* par une normalisation par groupes (*Group Normalization*). Une fois le modèle pleinement stabilisé, la prochaine grande étape sera la confrontation directe au terrain en inférant à grande échelle sur de véritables images Pléiades (0,50 m/px).

C’est lors de ce passage à l’échelle que le projet prendra toute sa dimension. Cette cartographie inédite de la flotte artisanale permettra de croiser l’observation spatiale de l’effort de pêche avec l’histoire récente et la réalité socio-économique malgache. L’objectif final sera d’en extraire des indicateurs socio-écologiques concrets, capables d’éclairer la vulnérabilité et la résilience des vil-

lages côtiers face aux mutations actuelles. Toutefois, lever le voile sur cette flotte « sombre » présente un caractère fondamentalement ambivalent qu'il conviendra d'assumer ouvertement. Si un tel détecteur peut se mettre au service d'une gestion participative et renforcer la reconnaissance politique des pêcheurs locaux, il peut à l'inverse alimenter une logique de surveillance et de contrôle purement punitive et descendante, susceptible de les pénaliser. Équilibrer ce double tranchant éthique sera au cœur des discussions de ce travail. En validant la faisabilité technique de cette détection, ce stage pose ainsi les fondations méthodologiques directes de mes trois prochaines années de thèse.

Déclaration d'utilisation de l'IA

L'assistance de GitHub Copilot et Claude Code a permis d'optimiser l'implémentation technique, tout comme Claude et QuillBot ont affiné la rédaction de ce document. L'apport de ces intelligences artificielles concerne toutefois uniquement la forme, l'intégralité du fond du travail restant mon œuvre propre.

Références

1. Airbus Defence and Space : Pléiades User Guide. Airbus DS (2019), <https://www.engesat.com.br/wp-content/uploads/PleiadesUserGuide-17062019.pdf>
2. Airbus Defence and Space : Pléiades Neo User Guide. Airbus DS (2021), https://wp-cdn.apollomapping.com/web_assets/user_uploads/2021/11/08103301/2021.10_PleiadesNeo_UserGuide-EarlyRelease_20211015.pdf
3. Aldubaikhi, A., Patel, S. : Advancements in Small-Object Detection (2023–2025) : Approaches, Datasets, Benchmarks, Applications, and Practical Guidance. *Applied Sciences* **15**(22), 11882 (Jan 2025). <https://doi.org/10.3390/app152211882>, <https://www.mdpi.com/2076-3417/15/22/11882>
4. Bahdanau, D., Cho, K., Bengio, Y. : Neural Machine Translation by Jointly Learning to Align and Translate (May 2016). <https://doi.org/10.48550/arXiv.1409.0473>, <http://arxiv.org/abs/1409.0473>, arXiv :1409.0473 [cs.CL]
5. Bastidas, A.A., Tang, H. : Channel Attention Networks. In : 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). pp. 881–888 (Jun 2019). <https://doi.org/10.1109/CVPRW.2019.00117>, <https://ieeexplore.ieee.org/document/9025565>, ISSN : 2160-7516
6. Basurto, X., Gutierrez, N.L., Franz, N., Mancha-Cisneros, M.d.M., Gorelli, G., Aguión, A., Funge-Smith, S., Harper, S., Mills, D.J., Nico, G., Tilley, A., Vannucini, S., Virdin, J., Westlund, L., Allison, E.H., Anderson, C.M., Baio, A., Cinner, J., Fabinyi, M., Hicks, C.C., Kolding, J., Melnychuk, M.C., Ovando, D., Parma, A.M., Robinson, J.P.W., H. Thilsted, S. : Illuminating the multidimensional contributions of small-scale fisheries. *Nature* **637**(8047), 875–884 (Jan 2025). <https://doi.org/10.1038/s41586-024-08448-z>, <https://www.nature.com/articles/s41586-024-08448-z>
7. Blythe, J.L., Claudet, J., Gill, D., Ban, N.C., Epstein, G., Gurney, G.G., Jupiter, S.D., Mahajan, S.L., Mangubhai, S., Turner, R., Bennett, N.J., D'Agata, S.,

- Franks, P., Lau, J., Ahmadi, G., Andrachuk, M., Annasawmy, P., Brun, V., Darling, E.S., Di Franco, A., Evans, L., Lazzari, N., Naggea, J., Relano, V., Pertuz, M.C., Villasante, S., Zafra-Calvo, N. : The Ocean Equity Index. *Nature* (2026). <https://doi.org/10.1038/s41586-025-09976-y>, <https://www.nature.com/articles/s41586-025-09976-y>
8. Bommasani, R., Hudson, D.A., Adeli, E., Altman, R., Arora, S. : On the Opportunities and Risks of Foundation Models. *arXiv preprint arXiv :2108.07258* (Jul 2022), <https://arxiv.org/abs/2108.07258>
9. Cheng, G., Yuan, X., Yao, X., Yan, K., Zeng, Q., Xie, X., Han, J. : Towards Large-Scale Small Object Detection : Survey and Benchmarks. *IEEE Transactions on Pattern Analysis and Machine Intelligence* pp. 1–20 (2023). <https://doi.org/10.1109/TPAMI.2023.3290594>, <https://ieeexplore.ieee.org/document/10168277/>
10. Ding, J., Xue, N., Long, Y., Xia, G.S., Lu, Q. : Learning RoI Transformer for Detecting Oriented Objects in Aerial Images. *arXiv preprint arXiv :1812.00155* (2018), <https://arxiv.org/abs/1812.00155>
11. Fattebert, C. : La pêche traditionnelle ou petite pêche maritime à madagascar : un état des lieux. Tech. rep., Coalition pour des Accords de Pêche Équitables (CAPE-CFFA) (2020), <https://static1.squarespace.com/static/5d9341270c6f505b38e59293/t/5e996a11c6f8c1542e9cb3ee/1587112603674/200415%2BReport%2BMadagascar.pdf>
12. Fisheries Transparency Initiative, Ministère de la Pêche et de l'Économie Bleue (MPEB) : Madagascar : Rapport national FiTI 2025. Tech. rep., Secrétariat National FiTI Madagascar (2026), https://www.mpeb.mg/wp-content/uploads/2026/04/MDG_FiTIReport2025_20260228.pdf
13. Guo, C., Zhang, Z., Huang, K., Luo, L., Yang, Z., Shi, S., Shi, J. : Deep Learning Methods for SAR and Optical Image Fusion : A Review. *Remote Sensing* **18**(8), 1196 (Jan 2026). <https://doi.org/10.3390/rs18081196>, <https://www.mdpi.com/2072-4292/18/8/1196>
14. Haque, S.A., Al Jufaili, S.M. : Applications of Artificial Intelligence in Fisheries : From Data to Decisions. *Big Data and Cognitive Computing* **10**(1), 19 (Jan 2026). <https://doi.org/10.3390/bdcc10010019>, <https://www.mdpi.com/2504-2289/10/1/19>
15. Huerta, J.C.C. : JulioContrerasH/satharmony (Apr 2026), <https://github.com/JulioContrerasH/satharmony>, original-date : 2026-01-12T11 :18 :16Z
16. Jocher, G., Qiu, J., Chaurasia, A. : Ultralytics YOLO (Jan 2023), <https://github.com/ultralytics/ultralytics>, original-date : 2022-09-11T16 :39 :45Z
17. Lam, D., Kuzma, R., McGee, K., Dooley, S., Laielli, M., Klaric, M., Bulatov, Y., McCord, B. : xview : Objects in context in overhead imagery. *arXiv preprint arXiv :1802.07856* (2018), <https://xviewdataset.org/>
18. Laval, L., Mouillot, D., Viguié, P. : Detecting two-pixels long boats on satellite images (2025)
19. Lin, T.Y., Dollár, P., Girshick, R., He, K., Hariharan, B., Belongie, S. : Feature Pyramid Networks for Object Detection (Apr 2017). <https://doi.org/10.48550/arXiv.1612.03144>, <http://arxiv.org/abs/1612.03144>, *arXiv :1612.03144 [cs.CV]*

20. Lin, T.Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., Zitnick, C.L. : Microsoft COCO : Common Objects in Context. In : Fleet, D., Pajdla, T., Schiele, B., Tuytelaars, T. (eds.) Computer Vision – ECCV 2014. pp. 740–755. Springer International Publishing, Cham (2014). https://doi.org/10.1007/978-3-319-10602-1_48
21. Luo, W., Li, Y., Urtasun, R., Zemel, R. : Understanding the Effective Receptive Field in Deep Convolutional Neural Networks. arXiv preprint arXiv :1701.04128 (2017)
22. Maleki, A.S., Imani, M. : Region-Aware Deformable Convolutions (2025). <https://doi.org/10.48550/ARXIV.2509.15436>, <https://arxiv.org/abs/2509.15436>, version Number : 1
23. Marsaglia, L., Parisi, A., Libralato, S., Miller, N.A., Davis, P., Paolo, F.S., Fiorentino, F., Garofalo, G., Costantini, M., Russo, T. : Shedding light on trawl fishing activity in the mediterranean sea with remote sensing data. ICES Journal of Marine Science **82**(2), fsae153 (Feb 2025). <https://doi.org/10.1093/icesjms/fsae153>, <https://academic.oup.com/icesjms/article/82/2/fsae153/7899435>
24. Menéndez-Blázquez, J., Segovia, M., March, D. : Leveraging Earth Observation Data to Monitor Boat-Based Recreational Fishing. Fish and Fisheries **26**(6), 1065–1074 (Nov 2025). <https://doi.org/10.1111/faf.70017>, <https://onlinelibrary.wiley.com/doi/10.1111/faf.70017>
25. Nogueira, K., Penatti, O.A., Dos Santos, J.A. : Towards better exploiting convolutional neural networks for remote sensing scene classification. Pattern Recognition **61**, 539–556 (Jan 2017). <https://doi.org/10.1016/j.patcog.2016.07.001>, <https://linkinghub.elsevier.com/retrieve/pii/S0031320316301509>
26. Ocean+ Habitats : Ocean+ Habitats (2026), <https://habitats.oceanplus.org>
27. Randriatsara, R.M., Behivoke, F., Ramahatratra, F., Mahafina, J., Lamy, T., Léopold, M. : Mapping place names for small-scale fisheries evaluation. Aquatic Living Resources **38**, 13 (2025). <https://doi.org/10.1051/alr/2025009>, <https://www.alr-journal.org/articles/alr/abs/2025/01/alr240083/alr240083.html>
28. SeaRates : Madagascar Ports - List of Ports in Madagascar (2026), <https://www.searates.com/fr/maritime/madagascar>
29. UICN, The Pew Charitable Trusts : Recommandations de l'UICN pour améliorer la classification des aires marines protégées. Tech. rep., The Pew Charitable Trusts (2018), <https://www.pew.org/-/media/assets/2018/03/recommandations--liucn-pour-amliorer-la-classification-les-aires-marines-protges.pdf>
30. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, L., Polosukhin, I. : Attention Is All You Need (Aug 2017). <https://doi.org/10.48550/arXiv.1706.03762>, <http://arxiv.org/abs/1706.03762>, arXiv :1706.03762 [cs.CL]
31. Viana, D.F., Zamborain-Mason, J., Gaines, S.D., Schmidhuber, J., Golden, C.D. : Nutrient supply from marine small-scale fisheries. Scientific Reports **13**(1), 11357 (Jul 2023). <https://doi.org/10.1038/s41598-023-37338-z>, <https://www.nature.com/articles/s41598-023-37338-z>
32. Wang, X., Xie, L., Dong, C., Shan, Y. : Real-ESRGAN : Training Real-World Blind Super-Resolution with Pure Synthetic Data. In : 2021 IEEE/CVF International Conference on Computer Vision Workshops (ICCVW). pp. 1905–1914. IEEE,

- Montreal, BC, Canada (Oct 2021). <https://doi.org/10.1109/ICCVW54120.2021.00217>, <https://ieeexplore.ieee.org/document/9607421/>
33. World Bank : Madagascar : trouver un équilibre entre conservation et exploitation des ressources marines (2020), <https://www.banquemonddiale.org/fr/news/feature/2020/06/08/madagascar-balancing-conservation-and-exploitation-of-fisheries-resources>
 34. Xu, L., Qiu, B., Xu, H., Ouyang, S., Zhu, X. : A robust network for tiny and arbitrary-oriented ship detection in remote sensing images. *Scientific Reports* **15**, 44596 (2025). <https://doi.org/10.1038/s41598-025-28381-z>, <https://www.nature.com/articles/s41598-025-28381-z>
 35. Xue, F., Jin, W., Qiu, S., Yang, J. : Rethinking automatic ship wake detection : State-of-the-art cnn-based wake detection via optical images. *IEEE Transactions on Geoscience and Remote Sensing* **60**, 1–22 (2022), <https://api.semanticscholar.org/CorpusID:244395626>
 36. Yildirim, E., Kavzoglu, T. : Deep convolutional neural networks for ship detection using refined DOTA and TGRS-HRRSD high-resolution image datasets. *Advances in Space Research* **75**(2), 1871–1887 (Jan 2025). <https://doi.org/10.1016/j.asr.2024.10.028>, <https://www.sciencedirect.com/science/article/pii/S027311772401055X>
 37. Yosinski, J., Clune, J., Bengio, Y., Lipson, H. : How transferable are features in deep neural networks? *arXiv preprint arXiv :1411.1792* (2014), <https://arxiv.org/abs/1411.1792>
 38. Yuan, X., Chakravarty, A., Lichtenberg, E.M., Gu, L., Wei, Z., Chen, T. : An empirical analysis of deep learning methods for small object detection from satellite imagery. *Expert Systems with Applications* **307**, 131061 (Apr 2026). <https://doi.org/10.1016/j.eswa.2025.131061>, <https://www.sciencedirect.com/science/article/pii/S0957417425046755>
 39. Zhao, T., Wang, Y., Li, Z., Gao, Y., Chen, C., Feng, H., Zhao, Z. : Ship Detection with Deep Learning in Optical Remote-Sensing Images : A Survey of Challenges and Advances. *Remote Sensing* **16**(7), 1145 (Jan 2024). <https://doi.org/10.3390/rs16071145>, <https://www.mdpi.com/2072-4292/16/7/1145>
 40. Zucchetta, M., Madricardo, F., Ghezzi, M., Petrizzo, A., Picciulin, M. : Satellite-based monitoring of small boat for environmental studies : A systematic review. *Journal of Marine Science and Engineering* **13**(3) (2025). <https://doi.org/10.3390/jmse13030390>, <https://www.mdpi.com/2077-1312/13/3/390>

A Hyperparamètres d'entraînement

Afin de garantir la reproductibilité de nos expériences, les listes suivantes détaillent l'ensemble des hyperparamètres maintenus constants lors des différents entraînements de notre étude d'ablation.

A.1 Configuration matérielle et optimisation

- **Taille d'image (*imgsz*)** : 1536.
- **Taille de batch (*batch_size*)** : 16.
- **Époques (*epochs*)** : 100 (maximum).
- **Arrêt précoce (*patience*)** : 20 époques.
- **Optimiseur** : AdamW.
- **Taux d'apprentissage initial (*lr0*)** : 0,001, avec un ordonnancement en cosinus (*cos_lr* activé).
- **Pondération de la fonction de perte** : 5,0 pour la régression des boîtes (*box*), 2,0 pour la classification (*cls*) et 1,0 pour l'orientation angulaire (*angle*).

A.2 Stratégie d'augmentation de données (*Data Augmentation*)

Les paramètres suivants définissent les perturbations appliquées aléatoirement aux images lors de la phase d'entraînement.

- **Augmentations géométriques** : Rotations jusqu'à 180° (*degrees*), retournements horizontaux (*fliplr*) et verticaux (*flipud*) avec une probabilité de 50 %, translations de 10 % (*translate*), et mises à l'échelle de 30 % (*scale*).
- **Recomposition spatiale** : *Mosaic* appliqué avec une probabilité de 70 % et désactivé lors des 20 dernières époques (*close_mosaic*). Le *Mixup* est appliqué avec une probabilité de 20 %.
- **Perturbations photométriques (YOLO)** : Variations sur l'espace HSV fixées à 3 % pour la teinte (*hsv_h*), 30 % pour la saturation (*hsv_s*) et 20 % pour la valeur (*hsv_v*).
- **Albumentations** : Flou (*Blur*, limite de 5, probabilité de 20 %), bruit gaussien (*GaussNoise*, limites [0.2, 0.44], probabilité de 30 %), CLAHE (limite de 4.0, probabilité de 30 %) et variations aléatoires de luminosité et de contraste (*RandomBrightnessContrast*, limites de 0.15, probabilité de 30 %).

B Stabilité des projections UMAP

L'algorithme de réduction de dimensionnalité UMAP utilisé dans la Section 5.3 étant par nature stochastique, la projection spatiale des caractéristiques peut varier en fonction de la graine aléatoire (*seed*) d'initialisation.

Afin de démontrer la robustesse de notre analyse visuelle, cette annexe présente deux projections supplémentaires générées avec des graines d’initialisation différentes ($seed = 53$ et $seed = 67$). Comme l’illustrent les Figures 7 et 8, bien que la topologie exacte du nuage de points varie légèrement d’une itération à l’autre, la dynamique globale reste strictement identique. Dans tous les cas de figure, on observe une superposition massive des domaines d’imagerie d’origine (Pléiades Neo) et des deux simulations (physique et stochastique), validant ainsi le fait que cette observation n’est pas un simple artefact algorithmique.




FIGURE 7 – Projections UMAP des vecteurs caractéristiques SatDINO ($seed = 53$).

C Illustration de la diversité des cibles : imagerie Pléiades Neo

Cette section présente trois exemples représentatifs de pirogues artisanales extraites de l’imagerie Pléiades Neo (0,30m/px).




FIGURE 8 – Projections UMAP des vecteurs caractéristiques SatDINO (seed = 67).



FIGURE 9 – **Exemples de pirogues artisanales en imagerie Pléiades Neo.** Illustration de la diversité des cibles : le modèle doit apprendre à les détecter dans des environnements côtiers variés, caractérisés par des reflets, des zones de houle et différents types de fonds marins.

Remerciements

Un immense merci à l'UMR Marbec et à toute l'équipe pour la formidable aventure qu'a été ce stage. Je remercie tout particulièrement David Mouillot de m'avoir accueilli, encouragé et écouté du premier au dernier jour.

Merci à tous mes super collègues du bâtiment 21, qui ont été là pour moi, autant pour m'épauler dans mon travail que pour m'aider à prendre mes marques à Montpellier. Merci à Luka pour sa présence et son super encadrement, et une pensée toute particulière pour Jing, Nino et Sébastien : merci d'avoir participé, jour après jour, à la transformation de notre bureau en une véritable jungle !

Je tenais aussi à dire un grand merci à Pauline, qui m'a énormément aidé à trouver ma thèse. Savoir que je pourrai compter sur ta présence pour les trois prochaines années est une vraie joie.

Enfin, merci à tous pour cet accueil si chaleureux, pour vos précieux conseils au quotidien, et pour ces mémorables parties de pétanque !

*Si ce travail vous intéresse ou si vous souhaitez en discuter, n'hésitez pas à me
contacter à l'adresse suivante :
thomas.aubourg@umontpellier.fr.*